

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
ІМЕНІ ІГОРЯ СІКОРСЬКОГО»

Інститут прикладного системного аналізу
Кафедра штучного інтелекту

ЗВІТ ДО ПРОЄКТУ

з дисципліни «Інноваційні сфери застосування нейронних мереж»

на тему:

«Аналіз нейромережевих послідовних та базових статичних
методів у задачах колаборативної фільтрації»

Виконав: аспірант групи [ГРУПА]
[ПІБ]

Перевірила: [ПІБ]

Київ, 2026

1 Мета роботи

Метою даного проєкту є систематичне порівняння восьми методів колаборативної фільтрації (послідовних та загальних) на єдиній відтворюваній методологічній основі. Конкретні завдання:

- оцінити якість рекомендацій кожної моделі за повним набором метрик (HR, NDCG, MRR, Precision) при порогах $K \in \{10, 20, 50, 100\}$;
- кількісно визначити розрив між послідовними та загальними підходами;
- встановити оптимальну модель за критерієм «якість / час навчання».

Набір даних: MovieLens-1M [1]. Реалізації моделей взяті з фреймворку RecBole [2]; гіперпараметри підбираються автоматично за допомогою Optuna [3].

2 Набір даних

MovieLens-1M [1] є загальнозживаним еталонним набором даних платформи GroupLens Research, що містить оцінки фільмів, зібрані з кінця 1990-х по 2003 рік. У даному дослідженні оцінки трактуються як сигнал неявного зворотного зв'язку (факт перегляду). Застосовано фільтрацію: залишаються лише користувачі та фільми з щонайменше 5 взаємодіями. Характеристики після фільтрації наведено в таблиці 1.

Табл. 1: Характеристики набору даних MovieLens-1M після фільтрації.

Параметр	Значення
Кількість взаємодій	1 000 209
Кількість користувачів	6 040
Кількість фільмів	3 706
Щільність матриці	4,47%

3 Методологія

3.1 Порівнювані моделі

Досліджуються вісім моделей двох сімейств (таблиця 2). *Загальні* методи (Pop, BPR [4], ItemKNN [5]) не враховують порядок взаємодій і є базовими моделями. *Послідовні* методи явно моделюють хронологічну послідовність: FPMC [6] поєднує матричну факторизацію з марківськими ланцюгами; GRU4Rec [7] використовує рекурентну мережу GRU; NARM [8] доповнює GRU механізмом уваги; SASRec [9] побудований на авторегресивній трансформерній увазі; BERT4Rec [10] адаптує двонаправлену увагу з маскуванням токенів BERT для задачі рекомендацій.

Табл. 2: Порівнювані моделі та їх ключові характеристики.

Модель	Сімейство	Ключова архітектурна ідея
Pop	загальна	ранжування за глобальною популярністю
BPR	загальна	парне ранжування з імпліцитним сигналом
ItemKNN	загальна	item-based колаборативна фільтрація
FPMC	послідовна	матрична факторизація + ланцюги Маркова
GRU4Rec	послідовна	рекурентна мережа (GRU)
NARM	послідовна	GRU + механізм м'якої уваги
SASRec	послідовна	авторегресивна трансформерна увага
BERT4Rec	послідовна	двонапрямлена увага з маскуванням токенів

3.2 Розбиття даних

Для кожного користувача взаємодії впорядковуються за часовою міткою. Остання взаємодія відводиться до тестової вибірки, передостання до валідаційної, а всі попередні до навчальної (*leave-one-out* стратегія; параметри RecBole: `LS=valid_and_test`, `order=T0`). Завданням моделі є правильно передбачити наступний фільм у персональній хронологічній послідовності користувача (*next-item prediction*).

3.3 Підбір гіперпараметрів

Автоматичний підбір гіперпараметрів здійснюється бібліотекою Optuna [3] з алгоритмом пошуку TPE та MedianPruner. Для кожної моделі виконується 10 пробних запусків по 10 епох (`HPO_TRIALS = 10`, `HPO_EPOCHS = 10`); фінальна модель навчається 50 епох (`FINAL_EPOCHS = 50`) з найкращою комбінацією гіперпараметрів. Стани досліджень зберігаються у SQLite-базі, що забезпечує можливість відновлення при перериванні.

3.4 Метрики оцінювання

Оцінювання проводиться у режимі повного словника (*full-vocabulary scoring*): кожна модель ранжує всі фільми набору даних для кожного тестового користувача, попередньо маскуючи об'єкти з його навчальної та валідаційної історії. Обчислюються чотири групи метрик при порогах $K \in \{10, 20, 50, 100\}$:

- **HR@K** (Hit Rate): частка користувачів, для яких цільовий фільм потрапив до топ- K ;
- **NDCG@K**: нормалізований дисконтований кумулятивний виграш, враховує позицію релевантного результату в ранжованому списку;
- **MRR@K**: середній зворотній ранг першого релевантного результату;

- **Precision@K**: частка релевантних об'єктів серед топ- K .

Оскільки у leave-one-out оцінюванні кожен користувач має рівно один тестовий об'єкт, $HR@K \equiv Recall@K$, тому Recall окремо не наводиться.

4 Результати

Повна таблиця результатів наведена в таблиці 3 (горизонтальна орієнтація). Порівняння середніх показників двох сімейств наведено в таблиці 4.

5 Аналіз результатів

Перевага послідовних моделей. Таблиця 4 демонструє різку різницю між двома сімействами: в середньому послідовні моделі перевищують загальні у 3.7–4.2 рази за ключовими метриками. Це підтверджує, що хронологічна структура взаємодій несе суттєву прогностичну інформацію, яку статичні методи не здатні використати. Навіть найпростіша послідовна модель (FPMC, $NDCG@10 = 0.0813$) вдвічі перевершує найкращу загальну базову модель (ItemKNN, $NDCG@10 = 0.0372$).

Лідер: GRU4Rec. Рекурентна модель GRU4Rec досягає найвищих значень за $NDCG@10 = 0.1436$, $HR@10 = 0.2467$, $MRR@10 = 0.1121$ та всіма метриками при $K \leq 50$. При цьому час навчання становить лише 644 с, що є помірним: майже утричі менший, ніж у SASRec (1952 с), і майже вчетверо менший, ніж у BERT4Rec (2473 с). Такий результат свідчить про те, що GRU ефективно вловлює короткострокові залежності у послідовностях взаємодій без надмірних витрат на навчання.

Трансформерні моделі: SASRec та BERT4Rec. SASRec та BERT4Rec є конкурентоспроможними ($NDCG@10$ відповідно 0.1272 та 0.1237) і перевершують GRU4Rec при великих порогах ($K \geq 50$): $HR@100$ у SASRec досягає 0.6313 проти 0.6151 у GRU4Rec. Це вказує на те, що трансформерна увага точніше охоплює довгострокові контекстні зв'язки, що корисно для завдань з широким списком рекомендацій. Проте значно більший час навчання обмежує їх застосовність у ресурсообмежених середовищах.

NARM. NARM ($NDCG@10 = 0.1163$) займає третє місце серед послідовних нейронних моделей. Механізм уваги дозволяє йому виділяти ключові точки сесії, проте двоетапна архітектура (GRU + увага) поступається чистій трансформерній увазі SASRec за кожним показником.

FPMC як гібридна модель. FPMC суттєво перевершує загальні базові моделі, однак значно відстає від повністю нейронних послідовних методів: $NDCG@10 = 0.0813$ проти

Табл. 3: Результати оцінювання на тестовій вибірці MovieLens-1M. $HR = Recall$ за протоколом leave-one-out. **Жирним** виділено найкраще значення у стовпці, підкресленням позначено друге. Train: час навчання фінальної моделі, с.

Модель	HR@K			NDCG@K			MRR@K			Precision@K			Train, с
	10	20	50	100	10	20	50	100	10	20	50	100	
Pop	0.0368	0.0687	0.1387	0.2257	0.0177	0.0257	0.0395	0.0535	0.0120	0.0142	0.0164	0.0176	8.5
BPR	0.0684	0.1210	0.2278	0.3609	0.0341	0.0474	0.0685	0.0901	0.0239	0.0275	0.0309	0.0328	91.3
ItemKNN	0.0745	0.1268	0.2422	0.3639	0.0372	0.0503	0.0730	0.0927	0.0261	0.0296	0.0332	0.0349	21.3
FPMC	0.1599	0.2349	0.3738	0.5063	0.0813	0.1003	0.1279	0.1494	0.0574	0.0626	0.0671	0.0690	514.6
GRU4Rec	0.2467	0.3455	0.5017	0.6151	0.1436	0.1685	0.1994	0.2178	0.1121	0.1188	0.1238	0.1254	644.7
NARM	0.2247	0.3253	0.4891	0.6127	0.1163	0.1416	0.1741	0.1942	0.0834	0.0903	0.0955	0.0973	468.3
SASRec	0.2444	0.3430	0.5119	0.6313	0.1272	0.1521	0.1857	0.2051	0.0916	0.0984	0.1038	0.1055	1952.1
BERT4Rec	0.2359	0.3454	0.5063	0.6248	0.1237	0.1512	0.1832	0.2024	0.0898	0.0973	0.1024	0.1041	2473.0

Табл. 4: Порівняння двох сімейств моделей (середні значення по групі).

Сімейство	NDCG@10	HR@10	MRR@10
Загальні (Pop, BPR, ItemKNN)	0.0297	0.0599	0.0207
Послідовні (FPMC, GRU4Rec, NARM, SASRec, BERT4Rec)	0.1184	0.2223	0.0869
Відношення (послідовні / загальні)	$\times 3.99$	$\times 3.71$	$\times 4.20$

0.1163 у NARM. Це вказує на обмеженість першопорядкового марківського наближення порівняно з нелінійними нейронними архітектурами.

6 Висновки

1. Послідовна колаборативна фільтрація, що враховує хронологічний порядок взаємодій, кардинально переважає статичні методи у задачі next-item prediction: середній приріст NDCG@10 становить ≈ 4 -кратний. Це робить моделювання часової динаміки практично обов'язковим для продакшн-рекомендаційних систем.
2. GRU4Rec є найкращою моделлю за інтегральним критерієм «якість / час навчання»: найвищий NDCG@10 = 0.1436 при помірних 644 с. SASRec та BERT4Rec доцільні тоді, коли пріоритетом є охоплення широкого списку ($K \geq 50$), а обчислювальні ресурси дозволяють витратити 2 000–2 500 с на навчання.
3. FPMC підтверджує важливість послідовності навіть у спрощеному марківському наближенні, однак для досягнення максимальної якості необхідні нелінійні нейронні архітектури.

Литература

- [1] F. M. Harper and J. A. Konstan, “The MovieLens datasets: History and context,” *ACM Trans. Interact. Intell. Syst.*, vol. 5, no. 4, Art. no. 19, Dec. 2015, doi: 10.1145/2827872.
- [2] W. X. Zhao et al., “RecBole: Towards a unified, comprehensive and efficient framework for recommendation algorithms,” in *Proc. 30th ACM Int. Conf. Inf. Knowl. Manage. (CIKM)*, Virtual Event, QLD, Australia, Nov. 2021, pp. 4653–4664, doi: 10.1145/3459637.3482016.
- [3] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proc. 25th ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining (KDD)*, Anchorage, AK, USA, Aug. 2019, pp. 2623–2631.
- [4] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proc. 25th Conf. Uncertainty Artif. Intell. (UAI)*, Montreal, QC, Canada, Jun. 2009, pp. 452–461.
- [5] B. Sarwar, G. Karypis, J. Konstan, and J. Riedl, “Item-based collaborative filtering recommendation algorithms,” in *Proc. 10th Int. Conf. World Wide Web (WWW)*, Hong Kong, May 2001, pp. 285–295, doi: 10.1145/371920.372071.
- [6] S. Rendle, C. Freudenthaler, and L. Schmidt-Thieme, “Factorizing personalized Markov chains for next-basket recommendation,” in *Proc. 19th Int. Conf. World Wide Web (WWW)*, Apr. 2010, pp. 811–820, doi: 10.1145/1772690.1772773.
- [7] B. Hidasi, A. Karatzoglou, L. Baltrunas, and D. Tikk, “Session-based recommendations with recurrent neural networks,” in *Proc. 4th Int. Conf. Learn. Represent. (ICLR)*, May 2016.
- [8] J. Li et al., “Neural attentive session-based recommendation,” in *Proc. 26th ACM Int. Conf. Inf. Knowl. Manage. (CIKM)*, Singapore, Nov. 2017, pp. 1419–1428, doi: 10.1145/3132847.3132926.
- [9] W.-C. Kang and J. McAuley, “Self-attentive sequential recommendation,” in *Proc. IEEE Int. Conf. Data Mining (ICDM)*, Singapore, Nov. 2018, pp. 197–206, doi: 10.1109/ICDM.2018.00035.
- [10] F. Sun et al., “BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer,” in *Proc. 28th ACM Int. Conf. Inf. Knowl. Manage. (CIKM)*, Beijing, China, Nov. 2019, pp. 1441–1450, doi: 10.1145/3357384.3357895.